

Examen de Series de Tiempo — Finanzas Cuantitativas

Pregunta 1. Descomposición y lectura de una serie con comportamiento SARIMA

a) Comportamiento de la tendencia, estacionalidad y residuo

La tendencia sube de forma continua desde aproximadamente 55 en 2015 hasta alrededor de 85 en 2025. No hay caídas bruscas ni quiebres, el crecimiento es casi lineal con una ligera curvatura hacia el final. Lo más importante aquí es que domina completamente el nivel de la serie.

El componente estacional muestra un patrón que se repite cada 12 meses de manera muy regular, con picos y valles en los mismos meses a lo largo de todos los años. La amplitud se mantiene constante alrededor de ± 7.5 , lo que indica que la estacionalidad es aditiva y no crece con el nivel de la serie.

El residuo oscila alrededor de cero con una amplitud pequeña (± 4 aproximadamente) y sin ninguna estructura visible. Parece ruido aleatorio puro, lo que confirma que la descomposición capturó bien los componentes sistemáticos.

b) ¿Por qué SARIMA es adecuado?

Porque la serie tiene dos fuentes de no estacionariedad al mismo tiempo. Por un lado, la tendencia creciente implica que la media no es constante, lo cual se trata con diferenciación ordinaria mediante el parámetro d . Por otro lado, la estacionalidad periódica implica correlación con los valores de hace exactamente s periodos, y eso se elimina con diferenciación estacional mediante el parámetro D . SARIMA combina ambas correcciones en un solo modelo junto con componentes AR y MA para capturar la autocorrelación restante.

c) Periodo estacional s

El periodo estacional es $s = 12$, porque los datos son mensuales y el patrón se repite cada 12 observaciones, es decir, una vez al año. Esto se confirma visualmente contando los ciclos del panel estacional: entre 2015 y 2025 hay aproximadamente 10 ciclos completos, uno por cada año.

d) Forma general del modelo SARIMA(p,d,q) $\times$ (P,D,Q) s

El modelo se escribe como:

$$\Phi_P(B^s) \cdot \phi_p(B) \cdot (1-B)^d \cdot (1-B^s)^D \cdot X_t = \Theta_Q(B^s) \cdot \theta_q(B) \cdot \varepsilon_t$$

Donde p es el orden AR ordinario (cuántos rezagos recientes explican X_t), d es el número de diferencias ordinarias para eliminar la tendencia, q es el orden MA ordinario (cuántos errores recientes entran al modelo), P es el orden AR estacional, D es el número de diferencias estacionales para eliminar la estacionalidad, Q es el orden MA estacional, y s es el periodo que indica cada cuántas observaciones se repite el patrón estacional.

Pregunta 2. Operadores de rezago, diferencias y notación backward

a) Definición del operador B

El operador backward B desplaza la serie un periodo hacia atrás en el tiempo. Se define como:

$$BX_t = X_{t-1}$$

Aplicándolo dos veces: $B^2X_t = B(BX_t) = B(X_{t-1}) = X_{t-2}$

Aplicándolo doce veces: $B^{12}X_t = X_{t-12}$

La regla general es $B^k \cdot X_t = X_{t-k}$

b) Diferencias ∇ y ∇_{12}

La primera diferencia ordinaria se calcula como:

$$\nabla X_t = (1-B)X_t = X_t - BX_t = X_t - X_{t-1}$$

La primera diferencia estacional de orden 12:

$$\nabla_{12}X_t = (1-B^{12})X_t = X_t - B^{12}X_t = X_t - X_{t-12}$$

Para el producto de ambas diferencias, primero expandimos el operador:

$$(1-B)(1-B^{12}) = 1 - B^{12} - B + B \cdot B^{12} = 1 - B - B^{12} + B^{13}$$

Aplicando a X_t :

$$(1-B)(1-B^{12})X_t = X_t - X_{t-1} - X_{t-12} + X_{t-13}$$

c) Expansión del lado izquierdo

El lado izquierdo completo es $(1 - 0.5B)(1 - B)(1 - B^{12})X_t$.

Del inciso anterior ya tenemos: $(1-B)(1-B^{12})X_t = X_t - X_{t-1} - X_{t-12} + X_{t-13}$

Ahora aplicamos $(1 - 0.5B)$ a ese resultado distribuyendo término a término:

$$= [X_t - X_{t-1} - X_{t-12} + X_{t-13}] - 0.5B \cdot [X_t - X_{t-1} - X_{t-12} + X_{t-13}]$$

Calculando $0.5B$ sobre cada término del segundo corchete:

$$0.5B \cdot X_t = 0.5X_{t-1}$$

$$0.5B \cdot X_{t-1} = 0.5X_{t-2}$$

$$0.5B \cdot X_{t-12} = 0.5X_{t-13}$$

$$0.5B \cdot X_{t-13} = 0.5X_{t-14}$$

Entonces la expresión queda:

$$= X_t - X_{t-1} - X_{t-12} + X_{t-13} - 0.5X_{t-1} + 0.5X_{t-2} + 0.5X_{t-13} - 0.5X_{t-14}$$

Agrupando los términos semejantes:

- X_t aparece una vez: X_t

- X_{t-1} aparece con -1 y -0.5: $-1.5X_{t-1}$

- X_{t-2} aparece con +0.5: $+0.5X_{t-2}$

- X_{t-12} aparece con -1: $-X_{t-12}$

- X_{t-13} aparece con +1 y +0.5: $+1.5X_{t-13}$

- X_{t-14} aparece con -0.5: $-0.5X_{t-14}$

Resultado final del lado izquierdo:

$$X_t - 1.5X_{t-1} + 0.5X_{t-2} - X_{t-12} + 1.5X_{t-13} - 0.5X_{t-14}$$

d) Expansión del lado derecho y modelo completo

El lado derecho es:

$$(1 + 0.4B)\varepsilon_t = \varepsilon_t + 0.4 \cdot B\varepsilon_t = \varepsilon_t + 0.4\varepsilon_{t-1}$$

El modelo completo en dominio temporal es:

$$X_t - 1.5X_{t-1} + 0.5X_{t-2} - X_{t-12} + 1.5X_{t-13} - 0.5X_{t-14} = \varepsilon_t + 0.4\varepsilon_{t-1}$$

e) Identificación de d, D y s

Revisando el modelo original $(1 - 0.5B)(1-B)(1-B^{12})X_t$:

Parámetro	Valor	Justificación
d	1	El factor $(1-B)$ aparece una vez
D	1	El factor $(1-B^{12})$ aparece una vez
s	12	La potencia del operador estacional es 12

Pregunta 3. ACF, PACF, AIC y BIC: identificación del tipo de serie

a) ¿Estacionaria o no estacionaria?

La serie parece estacionaria. Primero, oscila alrededor de cero durante todo el periodo sin mostrar tendencia creciente ni decreciente. Segundo, la varianza (amplitud de las oscilaciones) se mantiene aproximadamente constante a lo largo del tiempo, no se ensancha ni se estrecha. Tercero, no hay cambios estructurales ni quiebres de nivel visibles. Estos tres elementos son las condiciones visuales de estacionariedad en covarianza.

b) ¿AR, MA o ARMA? Orden plausible

Analizando la ACF: el rezago 1 es grande y significativo (sale claramente de la banda de confianza), y del rezago 2 en adelante los valores caen dentro de la banda. La ACF se corta bruscamente después del lag 1.

Analizando la PACF: el lag 1 es grande y significativo, el lag 2 también parece significativo, y del lag 3 en adelante los valores están dentro de la banda. La PACF se corta aproximadamente en el lag 2.

El patrón de PACF que se corta en el lag p mientras la ACF decae gradualmente es la firma característica de un proceso $AR(p)$. Propongo $AR(2)$ como modelo plausible.

c) Selección por AIC y BIC

Para el criterio AIC se elige el modelo con el valor más bajo. Comparando los cuatro candidatos: $AR(1)$ tiene 581.21, $AR(2)$ tiene 566.67, $MA(1)$ tiene 569.33 y $ARMA(1,1)$ tiene 568.81. El mínimo es $AR(2)$ con 566.67, por lo que el modelo preferido según AIC es $AR(2)$.

Para el criterio BIC también se elige el valor más bajo. Los valores son: $AR(1)$ con 587.80, $AR(2)$ con 576.56, $MA(1)$ con 575.92 y $ARMA(1,1)$ con 578.70. El mínimo es $AR(2)$ con 576.56, por lo que el modelo preferido según BIC también es $AR(2)$.

d) Modelo final

El modelo final sería $AR(2)$, porque todos los criterios apuntan en la misma dirección: la serie es estacionaria (no se necesita diferenciación), la PACF se corta en el lag 2 (firma AR), tanto

AIC como BIC seleccionan AR(2), y es el modelo más parsimonioso con mejor ajuste entre los candidatos.

Pregunta 4. Pronóstico y validación

a) Comportamiento del pronóstico

En cuanto a la tendencia, el pronóstico sí la captura: los valores pronosticados suben desde 113.59 en enero hasta un pico en mayo (121.78) y luego bajan en junio, lo que es coherente con la dirección general de la serie de entrenamiento.

En cuanto a la estacionalidad, la captura parcialmente: el patrón de subida y bajada mensual es correcto, pero la amplitud del pronóstico es menor que la de los valores observados.

En cuanto a subestimación o sobreestimación, el modelo subestima sistemáticamente en los seis periodos: en todos los casos el valor pronosticado queda por debajo del observado. Esto sugiere que el modelo no capturó completamente la intensidad del crecimiento reciente de la serie.

b) Cálculo del MAE

La fórmula es $MAE = (1/n) \cdot \sum |y_t - \hat{y}_t|$

Primero calculo cada error absoluto:

Periodo	Observado	Pronóstico	Error	Error
2023-01	114.43	113.59	0.84	0.84
2023-02	123.38	119.87	3.51	3.51
2023-03	128.69	120.94	7.75	7.75
2023-04	128.02	123.78	4.24	4.24
2023-05	129.30	121.78	7.52	7.52
2023-06	124.73	116.61	8.12	8.12
Suma				31.98

Suma de errores absolutos: $0.84 + 3.51 + 7.75 + 4.24 + 7.52 + 8.12 = 31.98$

$MAE = 31.98 / 6 = 5.33$

c) Cálculo del RMSE

La fórmula es $RMSE = \sqrt{(1/n) \cdot \sum (y_t - \hat{y}_t)^2}$

Primero calculo cada error al cuadrado:

Periodo	Error	Error ²
2023-01	0.84	$0.84^2 = 0.7056$
2023-02	3.51	$3.51^2 = 12.3201$
2023-03	7.75	$7.75^2 = 60.0625$
2023-04	4.24	$4.24^2 = 17.9776$
2023-05	7.52	$7.52^2 = 56.5504$

2023-06	8.12	$8.12^2 = 65.9344$
Suma		213.5506

Suma de errores al cuadrado: $0.7056 + 12.3201 + 60.0625 + 17.9776 + 56.5504 + 65.9344 = 213.5506$

Promedio: $213.5506 / 6 = 35.5918$

RMSE = $\sqrt{35.5918} = 5.97$

d) Diagnósticos adicionales

Primero, aplicaría la prueba de Ljung-Box sobre los residuos del modelo para verificar que no tienen autocorrelación significativa. Si el estadístico Q tiene un p-valor mayor a 0.05, los residuos son ruido blanco y el modelo capturó toda la estructura. Si hay autocorrelación residual, el modelo está mal especificado.

Segundo, revisaría la normalidad de los residuos con un histograma y la prueba de Jarque-Bera o Shapiro-Wilk. Esto es importante porque si los residuos no son normales, las bandas de confianza del pronóstico no son válidas.

También graficaría los residuos contra el tiempo para detectar heterocedasticidad o patrones no capturados, y revisaría la ACF de los residuos para ver si hay rezagos significativos que el modelo no modeló.

Pregunta 5. Identificación de un modelo SARIMA a partir de una serie financiera

a) Código Python para descargar serie financiera mensual

```
import yfinance as yf

import pandas as pd
data = yf.download('^GSPC', start='2010-01-01', end='2024-01-01')
serie = data['Close'].resample('M').last()
serie = serie.dropna()
serie.plot(title='S&P 500 Mensual')
```

b) Transformaciones antes de ajustar el modelo

Frecuencia: verificar que la serie esté en frecuencia mensual regular, usando `resample('M')` si los datos son diarios.

Valores faltantes: ejecutar `serie.isna().sum()` y aplicar interpolación o `dropna()` si los hay.

Logaritmos: si la varianza crece con el nivel (común en precios), aplicar `np.log(serie)` para estabilizarla.

Diferenciación ordinaria: aplicar la prueba ADF. Si el p-valor es mayor a 0.05 hay raíz unitaria y se necesita $d = 1$.

Diferenciación estacional: hacer descomposición estacional y aplicar prueba OCSB o CH para determinar si $D = 1$ es necesario.

c) Valores plausibles para d, D y s

De la Figura 4 se observa que la serie tiene tendencia creciente (sube de ~14 a ~23), lo que implica $d = 1$. Hay oscilaciones que sugieren componente estacional, por lo que $D = 1$. Los datos son mensuales con ciclo anual, entonces $s = 12$.

d) Modelo SARIMA propuesto

La ACF decae lentamente con lag 1 muy alto (~0.75) y los siguientes positivos. La PACF se corta después del lag 1. Esto sugiere AR(1) para la parte ordinaria. Para la parte estacional uso $P = 1$ y $Q = 1$ como punto de partida estándar.

Propongo: $\text{SARIMA}(1,1,1) \times (1,1,1)_{12}$

e) Criterios de selección y validación

Para seleccionar entre modelos candidatos usaría AIC y BIC, eligiendo el que tenga el valor más bajo en ambos criterios. También se puede usar `auto_arima` de `pmdarima` para búsqueda automática.

Para validar el modelo final revisaría: prueba de Ljung-Box sobre los residuos, normalidad con Jarque-Bera, y métricas MAE, RMSE y MAPE sobre un conjunto de prueba separado.

Pregunta 6. Descarga e identificación de un modelo SARIMA para ventas

a) Código Python para serie de ventas

```
import pandas as pd
df = pd.read_csv('ventas.csv', parse_dates=['fecha'], index_col='fecha')
serie_mensual = df['ventas'].resample('M').sum()
serie_mensual.plot(title='Ventas Mensuales')
```

b) Tendencia, estacionalidad y no estacionariedad

Sí existe tendencia: las ventas suben de aproximadamente 250 en 2013 a 500 en 2024 de forma continua. Sí existe estacionalidad: hay picos y valles que se repiten cada año y la amplitud de los ciclos crece con el nivel, lo que sugiere que la estacionalidad podría ser multiplicativa. La serie es no estacionaria porque ni la media ni la varianza son constantes.

c) Grados de diferenciación

Parámetro	Valor	Justificación
d	1	Hay tendencia creciente que se elimina con una diferencia ordinaria
D	1	Hay estacionalidad periódica anual
s	12	Serie mensual con ciclo anual

d) Modelo SARIMA candidato

La ACF decae muy lentamente con todos los lags positivos hasta el lag 20+ y hay picos en los múltiplos de 12. La PACF tiene un pico grande en lag 1 (~0.85), un pico negativo en lag 2 y un pico en lag 12. Esto me lleva a proponer AR(1) o AR(2) para la parte ordinaria y $P = 1$ para la parte estacional.

Modelo candidato: $\text{SARIMA}(1,1,1) \times (1,1,1)_{12}$

e) Pronósticos a 12 meses y métricas

```
from statsmodels.tsa.statespace.sarimax import SARIMAX
modelo = SARIMAX(serie_mensual, order=(1,1,1), seasonal_order=(1,1,1,12))
resultado = modelo.fit(dispatch=False)
pronostico = resultado.get_forecast(steps=12).predicted_mean
```

Las métricas que usaría son MAE para el error promedio en unidades originales, RMSE porque penaliza más los errores grandes, y MAPE para el error porcentual que facilita comparar entre series de distinta escala.

Pregunta 7. SARIMAX y versiones del modelo

a) Diferencias conceptuales

ARIMA modela una sola serie con tendencia mediante diferenciación, sin manejar estacionalidad explícita ni variables externas. ARIMAX es ARIMA más variables exógenas que entran linealmente en la ecuación de la media, pero sin componente estacional. SARIMA extiende ARIMA agregando diferenciación y componentes AR y MA estacionales, pero sin variables externas. SARIMAX es la versión más completa: combina SARIMA con variables exógenas.

b) Forma general del modelo SARIMAX

$$\Phi_P(B^s) \cdot \phi_p(B) \cdot (1-B)^d \cdot (1-B^s)^D \cdot X_t = \beta_1 Z_{\{1t\}} + \beta_2 Z_{\{2t\}} + \dots + \beta_k Z_{\{kt\}} + \Theta_Q(B^s) \cdot \theta_q(B) \cdot \varepsilon_t$$

Las variables exógenas $Z_{\{jt\}}$ entran en la parte determinista del modelo, afectando directamente la media condicional de X_t . Sus coeficientes β_j se interpretan como el efecto lineal de cada variable sobre la serie objetivo, controlando por la dinámica temporal.

c) ¿Por qué incorporar variable exógena?

De la Figura 6 se observa que tanto la serie objetivo (demanda/ventas) como la variable exógena (gasto en publicidad o indicador macro) tienen tendencias crecientes que se mueven en la misma dirección de forma sistemática. Cuando la exógena sube, la demanda también tiende a subir. Si esta covariación es sistemática y no esporádica, incluir la variable exógena reduce el error del modelo porque captura parte de la variación de X_t que de otro modo quedaría en el término de error.

d) Modelo SARIMAX plausible

Con base en la Figura 6, propongo $\text{SARIMAX}(1,1,1) \times (1,1,1)_{12}$ con una variable exógena. La parte $\text{ARIMA}(1,1,1)$ captura la tendencia y autocorrelación ordinaria, el componente estacional $(1,1,1)_{12}$ captura el patrón anual, y la variable exógena captura el efecto lineal del indicador externo.

e) Código Python con statsmodels

```
from statsmodels.tsa.statespace.sarimax import SARIMAX
modelo = SARIMAX(endog=serie_objetivo, exog=exogena,
                  order=(1,1,1), seasonal_order=(1,1,1,12))
resultado = modelo.fit(dispatch=False)
pronostico = resultado.get_forecast(steps=12, exog=exog_futura)
```

Para el pronóstico se necesitan los valores futuros de la variable exógena, que deben pasarse en el argumento `exog` del método `get_forecast`.

f) Ventajas y limitaciones

Ventaja 1: Mayor precisión predictiva, porque al incorporar información externa relevante el modelo reduce el error de pronóstico comparado con SARIMA puro.

Ventaja 2: Los coeficientes β_j permiten interpretar y cuantificar el efecto de cada variable exógena sobre la serie objetivo, lo que es útil para toma de decisiones.

Limitación 1: Para hacer pronósticos fuera de muestra se necesitan los valores futuros de las variables exógenas, que a su vez hay que estimar o suponer, introduciendo error adicional.

Limitación 2: Si se incluyen muchas variables exógenas correlacionadas entre sí, el modelo puede sobreajustar en la muestra de entrenamiento pero generalizar mal fuera de ella.

Pregunta 8. Ecuaciones de Yule-Walker

a) Ecuaciones en términos de autocovarianzas

Para el proceso AR(2): $X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \varepsilon_t$

Multiplico ambos lados por X_{t-k} y tomo esperanza. Para $k = 1$:

$$E[X_t \cdot X_{t-1}] = \phi_1 \cdot E[X_{t-1}^2] + \phi_2 \cdot E[X_{t-2} \cdot X_{t-1}] + E[\varepsilon_t \cdot X_{t-1}]$$

Como ε_t es ruido blanco independiente de X_{t-1} , el último término es cero, entonces:

$$\gamma(1) = \phi_1 \cdot \gamma(0) + \phi_2 \cdot \gamma(1)$$

Para $k = 2$:

$$E[X_t \cdot X_{t-2}] = \phi_1 \cdot E[X_{t-1} \cdot X_{t-2}] + \phi_2 \cdot E[X_{t-2}^2] + E[\varepsilon_t \cdot X_{t-2}]$$

El último término es cero, entonces:

$$\gamma(2) = \phi_1 \cdot \gamma(1) + \phi_2 \cdot \gamma(0)$$

b) Sistema en términos de autocorrelaciones

Divido cada ecuación entre $\gamma(0)$. La primera ecuación queda:

$$\gamma(1)/\gamma(0) = \phi_1 \cdot \gamma(0)/\gamma(0) + \phi_2 \cdot \gamma(1)/\gamma(0) \rightarrow \rho(1) = \phi_1 + \phi_2 \cdot \rho(1)$$

La segunda ecuación queda:

$$\gamma(2)/\gamma(0) = \phi_1 \cdot \gamma(1)/\gamma(0) + \phi_2 \cdot \gamma(0)/\gamma(0) \rightarrow \rho(2) = \phi_1 \cdot \rho(1) + \phi_2$$

Reordenando para forma matricial:

$$\begin{bmatrix} 1 & \rho(1) \end{bmatrix} \begin{bmatrix} \phi_1 \\ \phi_2 \end{bmatrix} = \begin{bmatrix} \rho(1) \end{bmatrix}$$

$$\begin{bmatrix} \rho(1) & 1 \end{bmatrix} \begin{bmatrix} \phi_1 \\ \phi_2 \end{bmatrix} = \begin{bmatrix} \rho(2) \end{bmatrix}$$

c) Recuperación de parámetros con la matriz de Toeplitz

La matriz $R = \begin{bmatrix} 1, \rho(1) \\ \rho(1), 1 \end{bmatrix}$ es una matriz de Toeplitz porque sus elementos dependen solo de la diferencia de índices. El sistema matricial es $R \cdot \phi = \rho$.

Si R es invertible (lo es siempre que $|\rho(1)| < 1$), se puede despejar: $\phi = R^{-1} \cdot \rho$

La inversa de la matriz 2×2 con $a = d = 1$ y $b = c = \rho(1)$ es:

$$R^{-1} = 1/(1-\rho(1)^2) \cdot \begin{bmatrix} 1, & -\rho(1) \\ -\rho(1), & 1 \end{bmatrix}$$

Sustituyendo los valores muestrales $\hat{\rho}(1)$ y $\hat{\rho}(2)$ se obtienen los estimadores $\hat{\phi}_1$ y $\hat{\phi}_2$.

d) Solución numérica con $\hat{\rho}(1) = 0.48$, $\hat{\rho}(2) = 0.04$

El sistema de Yule-Walker con los valores dados queda:

$$\phi_1 + 0.48 \cdot \phi_2 = 0.48 \quad \dots (1)$$

$$0.48 \cdot \phi_1 + \phi_2 = 0.04 \quad \dots (2)$$

Paso 1: de la ecuación (1) despejo ϕ_1 :

$$\phi_1 = 0.48 - 0.48 \cdot \phi_2$$

Paso 2: sustituyo en la ecuación (2):

$$0.48 \cdot (0.48 - 0.48 \cdot \phi_2) + \phi_2 = 0.04$$

Paso 3: expando:

$$0.2304 - 0.2304 \cdot \phi_2 + \phi_2 = 0.04$$

Paso 4: agrupo los términos con ϕ_2 :

$$(1 - 0.2304) \cdot \phi_2 = 0.04 - 0.2304$$

$$0.7696 \cdot \phi_2 = -0.1904$$

Paso 5: despejo ϕ_2 :

$$\phi_2 = -0.1904 / 0.7696 = -0.2474$$

Paso 6: sustituyo ϕ_2 en la ecuación (1) para obtener ϕ_1 :

$$\phi_1 = 0.48 - 0.48 \cdot (-0.2474) = 0.48 + 0.1188 = 0.5988$$

Verificación en ecuación (2): $0.48 \cdot (0.5988) + (-0.2474) = 0.2874 - 0.2474 = 0.04 \quad \checkmark$

Estimadores: $\hat{\phi}_1 \approx 0.60$ y $\hat{\phi}_2 \approx -0.25$

e) ¿Por qué son útiles las ecuaciones de Yule-Walker?

Son útiles por tres razones. Para identificación, al resolver el sistema para $p = 1, 2, 3, \dots$ los coeficientes que resultan insignificantes indican el orden correcto, lo cual equivale a leer la PACF. Para estimación, permiten obtener los parámetros AR directamente desde la ACF muestral sin necesidad de algoritmos de optimización numérica, lo que los hace computacionalmente eficientes. Finalmente, la conexión ACF-PACF: la PACF en el lag p es exactamente el último coeficiente ϕ_{pp} del sistema Yule-Walker de orden p , lo que explica por qué la PACF se corta en el lag p para un $AR(p)$.

Pregunta 9. Modelo GARCH

a) Definición ARCH y GARCH

El modelo ARCH(q) (Engle, 1982) modela la varianza condicional como función de los errores al cuadrado pasados:

$$\varepsilon_t \sim \sigma_t \cdot z_t, \quad z_t \sim N(0,1) \text{ i.i.d.}$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 \cdot \varepsilon_{t-1}^2 + \alpha_2 \cdot \varepsilon_{t-2}^2 + \dots + \alpha_q \cdot \varepsilon_{t-q}^2$$

Se requiere $\alpha_0 > 0$ y $\alpha_i \geq 0$ para garantizar que $\sigma_t^2 > 0$ siempre.

El modelo GARCH(p,q) (Bollerslev, 1986) generaliza ARCH incluyendo también varianzas condicionales pasadas:

$$\sigma^2_t = \alpha_0 + \sum \alpha_i \cdot \varepsilon^2_{t-i} + \sum \beta_j \cdot \sigma^2_{t-j}$$

Esto permite capturar la persistencia de volatilidad con muchos menos parámetros que ARCH.

b) Forma algebraica del GARCH(1,1)

El modelo tiene dos ecuaciones. La ecuación de la media:

$$X_t = \mu + \varepsilon_t$$

La ecuación de la varianza condicional:

$$\sigma^2_t = \alpha_0 + \alpha_1 \cdot \varepsilon^2_{t-1} + \beta_1 \cdot \sigma^2_{t-1}$$

Donde $\varepsilon_t = \sigma_t \cdot z_t$ con $z_t \sim N(0,1)$ i.i.d., y se requiere $\alpha_0 > 0$, $\alpha_1 \geq 0$, $\beta_1 \geq 0$ y $\alpha_1 + \beta_1 < 1$.

c) Interpretación de parámetros y volatility clustering

α_0 es la varianza base o nivel mínimo de volatilidad, siempre positivo. α_1 mide cuánto aumenta la varianza de hoy si ayer hubo un choque grande: si ε^2_{t-1} es alto, σ^2_t también subirá. β_1 mide la persistencia de la volatilidad pasada: si es alto, la volatilidad de ayer se transmite en gran medida a hoy. La suma $\alpha_1 + \beta_1$ mide la persistencia total; si está cerca de 1, los choques tardan mucho en disiparse.

El volatility clustering ocurre porque si β_1 es alto, un choque en el periodo t eleva σ^2_{t+1} , que a su vez eleva σ^2_{t+2} , y así sucesivamente de forma decreciente. Esto produce los periodos agrupados de alta y baja volatilidad que se observan en la Figura 8.

d) Propiedades importantes

Propiedad 1 — Positividad de la varianza: se requiere $\alpha_0 > 0$, $\alpha_1 \geq 0$ y $\beta_1 \geq 0$. Si alguna condición se viola, el modelo puede producir varianzas negativas, lo que no tiene sentido económico.

Propiedad 2 — Varianza incondicional finita: si $\alpha_1 + \beta_1 < 1$, el proceso es covarianza-estacionario y su varianza de largo plazo es $\sigma^2 = \alpha_0 / (1 - \alpha_1 - \beta_1)$. Esto significa que la volatilidad revierte a un nivel de largo plazo.

Propiedad 3 — Leptocurtosis: aunque se suponga z_t normal, la distribución marginal de ε_t tiene colas más pesadas que la distribución normal, lo que es consistente con la evidencia empírica de que los eventos extremos en finanzas ocurren con más frecuencia de lo que predice una distribución normal.

Propiedad 4 — Persistencia (IGARCH): si $\alpha_1 + \beta_1 = 1$, los choques de volatilidad no se disipan en el tiempo y la volatilidad tiene memoria infinita.

e) Aplicaciones en finanzas

Aplicación 1 — Value at Risk (VaR): el VaR mide la pérdida máxima esperada con una probabilidad dada en un horizonte de tiempo. Usando GARCH se obtiene una estimación dinámica del VaR que se actualiza cada periodo conforme cambia σ^2_t , en lugar de usar una volatilidad fija como en los métodos tradicionales.

Aplicación 2 — Pricing de opciones con volatilidad dinámica: el modelo Black-Scholes asume volatilidad constante, pero en la práctica cambia en el tiempo. GARCH permite incorporar esa dinámica para obtener precios más realistas, especialmente en opciones de largo plazo.

f) Comparación ARIMA/SARIMA vs GARCH

Dimensión	ARIMA / SARIMA	GARCH
Qué modela	La media condicional $E[X_t F_{t-1}]$	La varianza condicional $Var(X_t F_{t-1})$
Supuesto sobre errores	Varianza constante (homocedasticidad)	Varianza cambia en el tiempo
Para qué sirve	Pronosticar el nivel o dirección futura	Pronosticar el riesgo o incertidumbre
Uso conjunto	Se usan juntos: ARIMA para la media y GARCH sobre los residuos	—

En la práctica financiera el flujo de trabajo es: primero ajustar ARIMA/SARIMA para la media, luego aplicar la prueba ARCH-LM sobre los residuos, y si hay evidencia de heterocedasticidad condicional, ajustar GARCH sobre esos residuos para modelar la varianza.